# Data Mining

Raimundo Sánchez, PhD
Facultad de Ingeniería y Ciencias
Universidad Adolfo Ibáñez

### Raimundo Sánchez

- Ingeniero Industrial
- Doctor en Ingenieria de Sistemas Complejos
- Profesor de Data Science UAI
- Investigo deportes de resistencia
- Corredor de montañas







## Data Mining


Uso de datos y métodos cuantitativos para mejorar la toma de decisiones

### Análisis de datos en las empresas



### ¿Qué es Data Science?






**Machine learning**: How can we build computer systems that automatically improve with experience? (Mitchell 2006)


**Data mining:** The process of identifying valid, novel, potentially useful, and ultimately understandable patterns in data

(Fayyad, Piatetsky-Shapiro & Smith 1996)


#### Niveles de decisión




### Flujo de información




### **Ejemplo**




Durante la Segunda Guerra Mundial, se le pidió al estadístico Abraham Wald que ayudara a los británicos a decidir dónde añadir armadura a sus aviones






# Los 3 Niveles de la IA

- Sistemas automáticos
- Redes Neuronales
   Artificiales
- Robótica Cognitiva



### Singularidad cognitiva



SOURCE: RAY KURZWEIL, "THE SINGULARITY IS NEAR: WHEN HUMANS TRANSCEND BIOLOGY", P.67, THE VIKING PRESS, 2006. DATAPOINTS BETWEEN 2000 AND 2012 REPRESENT BCA ESTIMATES.


## The Washington Post

#### Exabytes: Documenting the 'digital age' and huge growth in computing capacity

#### THE WORLD'S CAPACITY TO STORE INFORMATION

This chart shows the world's growth in storage capacity for both analog data (books, newspapers, videotapes, etc.) and digital (CDs, DVDs, computer hard drives, smartphone drives, etc.)

#### In gigabytes or estimated equivalent



2000


#### COMPUTING POWER

Singularidad

digital

In 1986, pocket calculators accounted for much of the world's data-processing power.

#### Percentage of available processing power by device:



By Brien Vesteg
Washington Fost StaffWitter
Thursday, February 10, 2011; 11:17 PM

2007 .... ANALOG

#### 18.86 billion gigabytes

Paper, film, audiotape and vinyl: 6.2%

Analog videotapes: 93.8%

Other digital media: 0.8%\*

Portable media players, flash drives: 2%

DIGITAL

Portable hard disks: 2.4%

CDs and minidisks: 6.8%

 Computer servers and mainframe hard disks: 8.9%

Digital tape: 11.8%

DVD/Blu-ray: 22.8%

PC hard disks: 44.5%
123 billion gigabytes

\*Other includes chip cards, memory cards, floppy disks, mobile phones/PDAs, cameras/camcorders, video games

2007 DIGITAL

276.12 billion gigabytes

#### **Big data**




#### What is big data?

Every day, we create 2.5 quintillion bytes of data — so much that 90% of the data in the world today has been created in the last two years alone. This data comes from everywhere: sensors used to gather climate information, posts to social media sites, digital pictures and videos, purchase transaction records, and cell phone GPS signals to name a few. This data is **big data**.




#### DATA NEVER SLEEPS 7.0







#### Definition: Gartner's 3V of Big Data



Copyright: infoDiagram.com

Variety






# No basta con robots

Los humanos aún debemos hacer las preguntas!

### Realidad del trabajo con datos

La creatividad humana no es automatizable y se volverá muy valiosa.



#### Objetivos del curso


- Identificar elementos clave de la minería de datos
- Comprender cómo interactúan los elementos algorítmicos para afectar el rendimiento
- Comprender cómo elegir algoritmos para diferentes tareas de análisis
- Analizar los datos de una manera exploratoria y específica
- Implementar y aplicar algoritmos básicos para el aprendizaje supervisado y sin supervisión
- Evaluar con precisión el rendimiento de los algoritmos.

#### Calendario

```
02 mar 21 Introducción al Curso, R, RStudio, RMD y Github
09 mar 21 Data measurement, data types
16 mar 21 Exploratory Data analysis
23 mar 21 Outliers, Feature selection
30 mar 21 semana santa
06 abr 21 K-means, C-means
           (ENTREGA P1)
 13 abr 21 Jerárquico, DBSCAN, GMM
 20 abr 21 Evaluacion unsupervised
 27 abr 21 dimensionality reduction
04 may 21 regresion lineal multiple
           Regresión logística y perceptron multicapa
           (ENTREGA P2)
18 may 21 semana pausa
25 may 21 KNN, Naïve Bayes
 01 jun 21 Evaluación, ROC, K-fold
 08 jun 21 Decision Trees (Xgboost)
 15 jun 21 redes neuronales profundas
           Modelos de Ensamblados, Random forest
 22 jun 21
```

NF = 0.2 P1 + 0.3 P2 + 0.3 P3 + 0.2 Portafolio (Ayudantías)

#### **CRISP DM**



#### Método Taller - UAI

Como resultado de un análisis de diversos métodos de resolución de problemas, se genero el Método Taller FIC, que consiste en 5 etapas con objetivos acotados y asociados al desarrollo de la solución de ingeniería. Al pasar por los talleres los alumnos repiten este proceso hasta internalizarlo, y son capaces de aplicarlo en cualquier contexto.

TAPAS

INMERSION AL CONTEXTO

DEFINICION
DEL
PROBLEMA

DEFINICION
DE
SOLUCIONES

DESARROLLO Y
EVALUACION
DE
PROTOTIPOS

INTRODUCCION
AL MERCADO

TALLER DE INTRODUCCION A LA INGENIERIA

TALLER DE DISEÑO EN INGENIERÍA

TALLER DE INNOVACION TECNOLÓGICA

TALLER DE CAPSTONE

TALLERES

# Software que utilizaremos este semestre

- R
- RStudio
- GitHub

### **EJEMPLO**

https://github.com/raimun2/curso\_data\_mining

# Data Mining

Raimundo Sánchez, PhD
Facultad de Ingeniería y Ciencias
Universidad Adolfo Ibáñez